ML hw1 Report

學號:B05705001 系級: 資管四 姓名:黃意芹

請實做以下兩種不同feature的模型,回答第(1)~(2)題:

- 1. 記錄誤差值 (RMSE)(根據kaggle public+private分數),討論兩種feature的影響
 - (1) 抽全部9小時內的污染源feature當作一次項(加bias) RMSE
 - (2) 抽全部9小時內pm2.5的一次項當作feature(加bias)

RMSE	全部9小時內的污染源當作feature	全部9小時內pm2.5當作feature
private	5.65158	5.72749
public	6.02616	5.99585
average	5.83887	5.86167

由得到的RMSE可知,抽全部9小時內的污染源feature當作一次項的表現會比抽全部9小時內pm2.5的一次項當作feature更好,不過差距不是很大。原因可能是因為PM2.5跟其他污染源有關聯,所以增加更多feature對於預測PM2.5會有所幫助。不過因為PM2.5本身就算是最主要的特徵,且其他資料可能有摻雜許多雜亂、異常的值,所以增加其他特徵的進步幅度沒有非常大。

- 2. 解釋什麼樣的data preprocessing 可以improve你的training/testing accuracy, e
- x. 你怎麼挑掉你覺得不適合的data points。請提供數據(RMSE)以佐證你的想法。

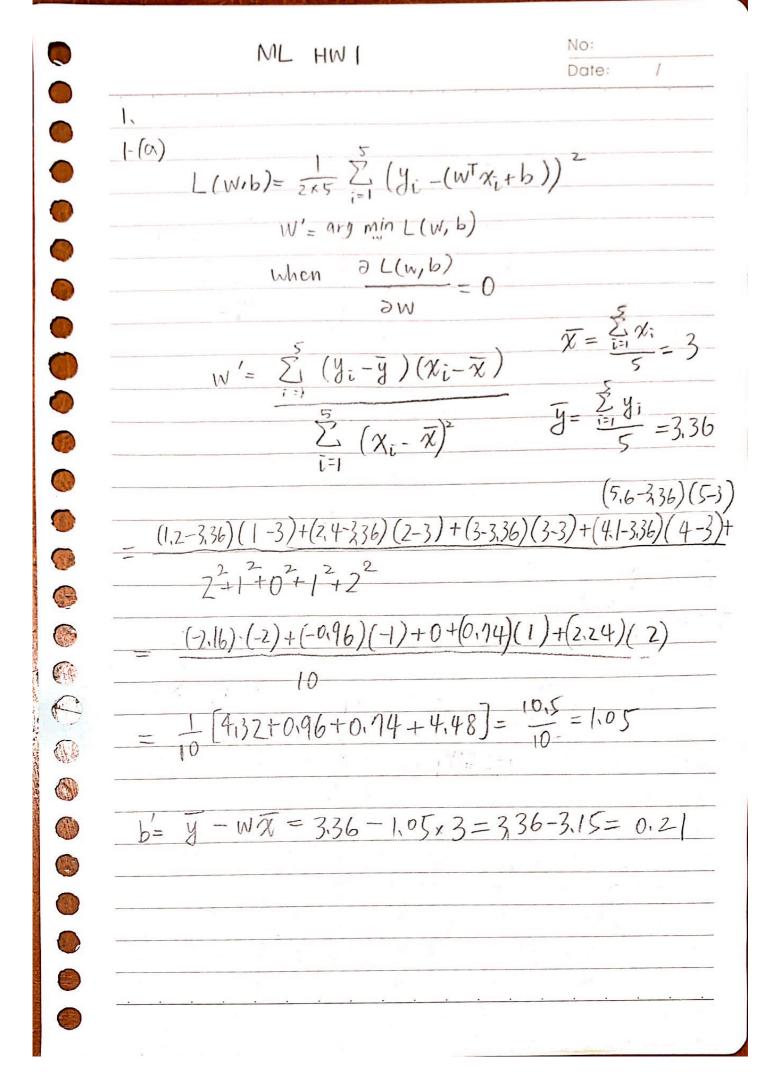
RMSE	全部9小時內的污染源當作feature	全部9小時內的污染源當作feature
	且有清除掉異常pm2.5	沒有清除掉異常pm2.5
private	5.69725	5.65158
public	5.54239	6.02616
average	5.61982	5.83887

除了 NR皆設為0,還有把在字尾的其他符號去除只留數字,我還有做資料清理方法為:先把pm2.5的極端值挑出(pm2.5 < 2 or pm2.5 >= 100),之後算出pm2.5的平均和標準差,將平均+-3.6*標準差以外的training data丟掉。在predict時,若testing data有pm2.5的值在平均+-3.8*標準差以外,則取代成平均值進行預測。會

這麼做的原因在於,pm2.5本身為最重要的特徵,然而資料有一些異常值,所以先清除掉再訓練出的model會比較準確。而testing data因為沒辦法丟掉資料,所以就把異常值取代為平均值進行預測。

從上表RMSE可觀察到,有去除異常pm2.5的model表現明顯較好。這是因為訓練與預測時不會被異常值誤導,所以結果也會比較準確。

3. Refer to math problem



No: Date: 1-(b) To find w, b that minimize L(w,b) = 2 (W,b) = 0 = 2 = 2 = (yi - b - wx;) = =0 => = yixi- = wxi- = bxi=0 $\Rightarrow \sum_{i=1}^{n} y_i \chi_i - \sum_{i=1}^{n} (\bar{y} - b\bar{\chi}) \chi_i - w \sum_{i=1}^{n} \chi_i^2 = 0$ $\Rightarrow \sum_{i=1}^{N} y_i \chi_i - \sum_{i=1}^{N} \overline{y} \chi_i + \sum_{i=1}^{N} w \overline{\chi} \chi_i - w \sum_{i=1}^{N} \chi_i^2 = 0$ $= N \sum_{i=1}^{N} \chi_{i}(\overline{\chi} - \chi_{i}) + \sum_{i=1}^{N} \chi_{i}(y_{i} - \overline{y}) = 0$ $\Rightarrow W = \sum_{i=1}^{N} \chi_{i}(y_{i} - \overline{y}) = \sum_{i=1}^{N} \chi_{i}y_{i} - \overline{y} \sum_{i=1}^{N} \chi_{i}$ $\frac{\sum_{i=1}^{N} \chi_{i}(\chi_{i} - \bar{\chi})}{\sum_{i=1}^{N} \chi_{i}(\chi_{i} - \bar{\chi})} = \frac{\sum_{i=1}^{N} \chi_{i}^{2} - \bar{\chi} Z \chi_{i}}{\sum_{i=1}^{N} \chi_{i}(\chi_{i} - \bar{\chi})}$ = Z74-N77-N77+N77 771-N72 アメソーンスターアスタン+アスタ ZX; -2NX+NX2 b= y- 2(x-x)(y-y) x

Date: /

1-(C)

(in

$$L_2(W,b) = \frac{1}{2N} \sum_{i=1}^{N} (y_i - (W_{X_i} + b))^2 + \frac{\lambda}{2} ||w||^2$$

$$\Rightarrow -\frac{1}{N} \sum_{i} y_{i} x_{i} - b x_{i} - w x_{i}^{2} + \lambda w = 0$$

$$\Rightarrow W = \frac{\sum y_i \chi_i - \sum y_i \chi_i}{\sum \chi_i (\chi_i - \overline{\chi}) + \lambda N} = \frac{\sum (y_i - \overline{y}) (\chi_i - \overline{\chi})}{\sum (\chi_i - \overline{\chi}) + \lambda N}$$

E

2、由1、(2) 把7、代技成 7:+1,

由1.(3) {2,50 } regularization 69 optimal weight

$$W_1 = \frac{\sum (\chi_i - \bar{\chi})(y_i - \bar{y})}{\sum (\chi_i - \bar{\chi})^2 + \bar{b}^2 N}$$

岩 Wo=W, 到可證得minimizing两岩LO的局的, 与相同

$$53: E(\sum_{i=1}^{n} (x_i + n_i - x)(y_i - y)) = \sum_{i=1}^{n} (E(x_i + n_i - x)(y_i - y))$$

$$= \sum_{i=1}^{n} (E(x_i + n_i - x)(y_i - y)) = \sum_{i=1}^{n} (E(x_i + n_i - x)(y_i - y))$$

$$= \sum_{i=1}^{n} \left(E\left(x_{i}y_{i} - x_{i}\overline{y} + n_{i}\overline{y} - n_{i}\overline{y} - \overline{x}y_{i} + \overline{x}\overline{y} \right) \right)$$

$$= E\left(x_{i}y_{i} - x_{i}\overline{y} + n_{i}\overline{y} - \overline{x}y_{i} + \overline{x}\overline{y} \right)$$

$$= \sum_{i=1}^{N} \left(E(x_i y_i - x_i \overline{y} - \overline{x} y_i + \overline{x} \overline{y}) \right) = \sum_{i=1}^{N} E(x_i - \overline{x})(y_i - \overline{y})$$

$$\widehat{\eta} \oplus : \mathbb{E}(\widehat{\Sigma}(\chi_i + n_i - \chi_i)^2) = \widehat{\Sigma}[\mathbb{E}(\chi_i - \chi_i + n_i)^2]$$

$$= \sum_{i=1}^{N} \left[E(x_i - \overline{x})^2 + 2 \cdot E(x_i - \overline{x})(n_i) + E(n_i^2) \right]$$

$$= \frac{1}{2} \left[E(\chi_i - \chi)^2 + \sigma^2 \right] = \frac{N}{i=1} (\chi_i - \chi) + N \sigma^2$$